



Análisis de Reservas y Cancelaciones Hoteleras

Hotel Booking Demand Dataset

By Lijia Gong



1. Introducción.....	3
1.1 Contexto del Proyecto.....	3
1.2 Motivación y Elección del Tema.....	3
1.3 Objetivos del Proyecto.....	3
1.4 Alcance del Trabajo.....	4
2. Metodología.....	4
2.1. Datos utilizados.....	4
2.1.1. Selección y Descripción de Variables Clave (Feature Selection).....	5
2.2. Extracción de datos.....	6
2.3. Proceso ETL (Extracción, Transformación y Carga) y Limpieza.....	6
2.4. Análisis de datos y Visualización.....	7
3. Análisis y resultados.....	9
3.1. Visión Global: La gravedad de la Tasa de Cancelación.....	9
3.2. Segmentación por Tipo de Hotel: City Hotel vs. Resort Hotel.....	10
3.3. Análisis por Tipo de Cliente: La dependencia de la volatilidad.....	11
3.4. El Valor de la Fidelización: Clientes Nuevos vs. Recurrentes.....	12
3.5. Anomalías en la Política de Depósitos: El caso "Non Refund".....	14
3.6. El Riesgo de la Antelación (Lead Time).....	15
3.7. El Precio (ADR) no es el culpable principal.....	16
3.8. La Psicología del Cliente: Peticiones Especiales.....	17
3.9. Estacionalidad y Estrategia de Precios (ADR).....	18
3.10. Distribución y Dependencia de Terceros (OTAs).....	19
3.11. Modelado Predictivo (Machine Learning).....	20
4. Definición del sistema BI.....	24
a. Capa de Negocio.....	24
b. Capa de BackOffice.....	25
5. Solución BI / Cuadro de mando.....	26
5.1. Construcción de la Solución.....	26
5.2. Características y Funcionalidades por Página.....	27
5.3. Toma de Decisiones Empresariales.....	30
6. Gestión de proyecto.....	31
6.1. Cronograma y Sprints (1 Mes).....	31
6.2. El Triángulo de Gestión (Alcance, Tiempo y Coste).....	31
6.3. Gestión de Riesgos y Conocimiento.....	32
7. Conclusiones y recomendaciones.....	33
7.1. Conclusiones Principales del Negocio.....	33
7.2. Recomendaciones Estratégicas.....	33
7.3. Recomendaciones para la Escalabilidad del Proyecto.....	34
8. Referencia.....	35
9. Anexo de Registro de Prompts Reales Utilizados en el Proyecto.....	36

1. Introducción

1.1 Contexto del Proyecto

La industria hotelera genera miles de datos diarios, pero tener datos crudos no equivale a tener conocimiento útil. Este proyecto busca cerrar esa brecha analizando un historial transaccional de reservas (*Hotel Bookings*) perteneciente a dos tipos de establecimientos: hoteles de ciudad (*City Hotel*) y vacacionales (*Resort Hotel*). El objetivo es transformar esta información en una herramienta visual que explique el comportamiento de los clientes y la variación de los ingresos a lo largo del tiempo.

1.2 Motivación y Elección del Tema

La hotelería enfrenta un gran desafío financiero: la **incertidumbre** de las cancelaciones, que se traduce en habitaciones vacías e ingresos perdidos. Además, es vital dominar el ADR (Tarifa Diaria Promedio) para vender al precio adecuado en el momento óptimo. Este proyecto, que sirve como culminación de tres meses de formación intensiva en Big Data, aplica técnicas de *Business Intelligence* para hacer visibles los problemas y las soluciones que una simple hoja de cálculo no puede mostrar.

1.3 Objetivos del Proyecto

El objetivo central es desarrollar una solución analítica que responda a preguntas estratégicas del negocio:

- **Identificar patrones de comportamiento:** Entender qué perfil de cliente (nuevo vs. recurrente) es más propenso a cumplir con su reserva.
 - **Analizar la estacionalidad:** Determinar los picos de demanda y cómo fluctúan los precios en esos periodos.
 - **Evaluar las cancelaciones:** Analizar críticamente cómo el tipo de depósito, la antelación (*lead time*) o las peticiones especiales afectan la tasa de cancelación.
 - **Desarrollar un modelo predictivo:** Implementar algoritmos de Machine Learning (como Random Forest) para anticipar con precisión la probabilidad de cancelación de cada reserva individual antes de la fecha de llegada.
-

-
- **Optimizar la toma de decisiones:** Diseñar un cuadro de mando interactivo en Power BI que permite explorar todos estos datos de forma visual y accesible.

1.4 Alcance del Trabajo

El proyecto abarca el ciclo de vida completo de un análisis de datos *end-to-end*. Inicia con la extracción y limpieza profunda de los datos (garantizando su fiabilidad), seguido de la construcción de un modelo dimensional eficiente (esquema en estrella). Concluye con la creación de métricas de negocio complejas y la entrega de un sistema interactivo en Power BI, proporcionando a la gerencia una herramienta rápida y escalable para filtrar la información y extraer conclusiones claras.

2. Metodología

Para llevar a cabo este proyecto, se adoptó un enfoque metodológico estructurado y secuencial, conocido en la industria como un proceso *end-to-end* (de principio a fin). Este enfoque abarca desde la obtención de la información en bruto hasta su presentación visual. Para lograr el mejor rendimiento y flexibilidad, se decidió combinar la potencia de programación de Python para la preparación de los datos, con la capacidad visual y analítica de Power BI para el resultado final.

2.1. Datos utilizados

El punto de partida del proyecto fue un conjunto de datos (*dataset*) histórico de reservas hoteleras. Para este análisis se ha utilizado el conjunto de datos de demanda de reservas hoteleras proporcionado por Antonio et al. (2019), el cual contiene registros reales de un hotel de ciudad y uno de resort (Mostipak, 2020).

Y el *dataset* contaba con más de 30 columnas de información transaccional. Sin embargo, para cumplir con los objetivos de este proyecto y evitar el "ruido" estadístico, el análisis se centró en un subconjunto de variables clave. Estas variables fueron seleccionadas por su alto impacto directo en la rentabilidad del hotel y en el comportamiento del usuario.

2.1.1. Selección y Descripción de Variables Clave (Feature Selection)

A continuación, se detallan las variables más críticas que forman el núcleo de nuestro Cuadro de Mando en Power BI, agrupadas por su función analítica:

1. Variable Objetivo (Target)

Es la métrica principal que nuestro proyecto intenta comprender y, en última instancia, reducir.

- **IsCanceled (Estado de Cancelación):** Se trata de una variable binaria (1 = Cancelada, 0 = No Cancelada). Es el corazón del análisis, ya que nos permite cruzarla con todas las demás variables para descubrir qué factores aumentan la probabilidad de que un cliente abandone su reserva.

2. Métricas Financieras y de Valor

- **ADR (Average Daily Rate):** Representa la Tarifa Diaria Promedio. Es, junto con el volumen de reservas, el indicador financiero más importante del sector hotelero. Nos permite analizar la elasticidad del precio: ¿las cancelaciones aumentan cuando el ADR es más alto? ¿Cómo varía el precio entre el *City Hotel* y el *Resort Hotel* durante el verano?

3. Variables de Comportamiento del Cliente (Predictores)

Estas son las variables que nos ayudan a perfilar al huésped y a encontrar los motivos ocultos detrás de sus decisiones.

- **IsRepeatedGuest (Fidelidad del cliente):** Variable que identifica si el huésped es nuevo o recurrente. Durante el análisis, esta columna demostró ser el indicador más fuerte de compromiso, revelando que los clientes habituales cancelan significativamente menos.
 - **LeadTime (Antelación de la reserva):** Mide los días transcurridos desde que se hace la reserva hasta el día de llegada. Es vital para la planificación operativa del hotel, ya que una reserva hecha con 6 meses de antelación tiene un riesgo de cancelación muy distinto a una hecha con 3 días.
 - **DepositType (Tipo de Garantía):** Indica si el cliente dejó un depósito (reembolsable o no reembolsable) o si reservó sin pagar por adelantado.
-

4. Variables Temporales y de Segmentación

- **ArrivalDateMonth / Year (Temporalidad):** Indispensables para la construcción de nuestra tabla de Calendario dinámica. Permiten analizar la fuerte estacionalidad del turismo, identificando los valles de invierno y los picos de verano.
- **CustomerType y DistributionChannel (Canales):** Nos ayudan a entender el origen del negocio. Diferenciar entre clientes individuales (*Transient*), grupos y agencias de viaje (*TA/TO*) permite al hotel saber en qué canales de marketing debe invertir más presupuesto.

2.2. Extracción de datos

En lugar de extraer la información directamente desde el software de gestión del hotel (PMS), los datos fueron obtenidos y descargados desde **Kaggle**, una de las comunidades de ciencia de datos más grandes y reconocidas del mundo.

El archivo se descargó en formato plano estructurado (CSV). Utilizar este formato es una práctica muy común, ya que simula a la perfección cómo los sistemas reales de los hoteles exportan sus bases de datos históricas para que los analistas puedan trabajar con ellas sin afectar el sistema en vivo.

2.3. Proceso ETL (Extracción, Transformación y Carga) y Limpieza

El corazón técnico de este proyecto fue la fase de preparación de los datos. En el mundo real, los datos nunca vienen perfectos, por lo que fue necesario realizar un riguroso proceso de limpieza. Para esta etapa, se utilizó Python, específicamente su librería **Pandas** (McKinney, 2010), debido a su gran capacidad y rapidez para manejar grandes volúmenes de información mediante código.

El proceso de limpieza se dividió en las siguientes cuatro etapas fundamentales:

- **1. Auditoría de Valores Nulos y Columnas Innecesarias:**

El primer paso consistió en evaluar la salud del *dataset*. Se programó una rutina para calcular la cantidad y el porcentaje de valores nulos (*Missing_count*) en cada columna. Tras este análisis, se decidió eliminar por completo las columnas *agent* y *company* mediante la función *drop*, ya que

presentaban vacíos o identificadores que no aportaban valor estratégico a nuestros objetivos de negocio y solo aportaban "ruido" al modelo.

- **2. Detección y Tratamiento de Valores Atípicos (Outliers):**

Para asegurar que los promedios y sumas no se vieran distorsionados por datos erróneos, se utilizaron las librerías gráficas *matplotlib* (Hunter, 2007) y *seaborn* (Waskom, 2021). Se generaron gráficos de caja (*boxplots*) para visualizar la distribución de variables clave como la antelación, las noches de estancia, el número de huéspedes y el precio (ADR). Basándonos en estas evidencias visuales, se aplicaron filtros lógicos estrictos:

- Se eliminaron las reservas con tarifas (ADR) nulas, negativas o irrealmente altas (limitando el rango entre 0 y 1000).
 - Se establecieron topes lógicos de capacidad por reserva (máximo 5 adultos, 4 niños y 2 bebés).
- **3. Enriquecimiento de Datos (Feature Engineering):** Para facilitar el análisis en el cuadro de mando final, se crearon nuevas variables (columnas calculadas) a partir de los datos existentes.
 - Se sumaron las columnas de niños y bebés para crear una columna unificada llamada *kids*.
 - Se sumaron los niños y los adultos para obtener el tamaño total del grupo (*total_person*).
 - Se unificaron las noches de fin de semana y las de entre semana para calcular la duración real de la estancia (*total_nights*).
 - **4. Transformación de Formatos y Fechas:** Finalmente, se adaptó el formato de los datos para que el modelo en Power BI fuera más amigable y fácil de interpretar.
 - **Mapeo de variables:** Las columnas binarias numéricas (0 y 1) se transformaron en etiquetas de texto legibles. Por ejemplo, *is_canceled* pasó a mostrar "Canceled" o "Not Canceled", y *is_repeated_guest* se transformó en "New Guest" o "Repeated Guest", conservando siempre una copia numérica por si fuera necesaria para cálculos futuros.
 - **Reconstrucción del Calendario:** Se unieron las columnas separadas de año, mes y día, para construir una nueva columna llamada *complete_arrival_date*. Esta columna se convirtió exitosamente al
-

formato *Datetime*, lo cual es el pilar fundamental para poder realizar los análisis de estacionalidad en Power BI.

2.4. Análisis de datos y Visualización

Una vez que los datos fueron limpiados y estructurados correctamente con Python, el archivo resultante fue importado a **Power BI**, la herramienta elegida para la fase analítica y visual.

Dentro de Power BI, se realizaron las siguientes acciones clave:

- **Conexión del Modelo:** Se conectaron las tablas creadas previamente y se generó una tabla de "Calendario" dinámica. Esto es fundamental para poder analizar la estacionalidad y ver cómo cambian los datos mes a mes o año a año.
- **Creación de métricas con DAX:** Se utilizó el lenguaje de fórmulas DAX para crear medidas de negocio inteligentes. No nos limitamos a sumar números, sino que calculamos porcentajes complejos como la Tasa de Cancelación, etc.
- **Diseño del Cuadro de Mando:** Finalmente, todas estas métricas se plasmaron en un panel interactivo (*Dashboard*). Se utilizaron gráficos modernos que permiten al usuario final hacer clic en cualquier mes o tipo de hotel y ver cómo toda la información se actualiza al instante, facilitando un análisis descriptivo (qué pasó) y de diagnóstico (por qué pasó).

2.5. Modelado Predictivo y Evaluación

Para transformar los datos en herramientas de decisión, se implementó una fase de aprendizaje supervisado utilizando la librería **Scikit-learn** (Pedregosa et al., 2011). El proceso incluyó:


- **Selección de Algoritmos:** Se entrenó un modelo de Regresión Logística como base (*baseline*) y un Random Forest (Breiman, 2001) como modelo avanzado para capturar patrones no lineales complejos.
 - **División de Datos:** El dataset se dividió en un conjunto de entrenamiento (80%) para el aprendizaje y uno de prueba (20%) para validar la precisión con datos "reales" no vistos por el modelo.
-

- **Optimización de Parámetros:** Se utilizó la técnica de *GridSearchCV* para realizar una búsqueda exhaustiva de los mejores hiperparámetros (como la profundidad de los árboles y el número de estimadores), garantizando la mayor eficiencia sin caer en el sobreajuste (*overfitting*).
- **Métricas de Validación:** La robustez del sistema se evaluó mediante Matrices de Confusión, analizando el equilibrio entre la precisión (evitar falsas alarmas) y el *Recall* (capacidad de detectar cancelaciones reales).

3. Análisis y resultados

En esta sección se presentan los descubrimientos más relevantes obtenidos tras la exploración visual y estadística de los datos. A continuación, se detallan los hallazgos clave apoyados por los gráficos generados durante el estudio:

3.1. Visión Global: La gravedad de la Tasa de Cancelación



Para entender la salud general del negocio, el primer paso fue analizar el volumen total de reservas que llegan a término frente a las que no.

- **Evidencia visual:** Según el gráfico de pastel y su correspondiente gráfico de barras de recuento absoluto, observamos que **el 37.6%** de las reservas totales son canceladas, mientras que el 62.4% se completan con éxito (aproximadamente 44,000 cancelaciones frente a 73,000 reservas efectivas).
- **Insight de negocio:** Una tasa global de cancelación cercana al 38% es alarmantemente alta. Esto significa que más de 1 de cada 3 reservas que

entran al sistema (*PMS*) se pierden antes de que el cliente pise el hotel. Operativamente, esto genera un problema grave de previsión: el hotel cree tener una ocupación alta y puede rechazar a otros clientes, para luego encontrarse con habitaciones vacías de forma repentina.

3.2. Segmentación por Tipo de Hotel: City Hotel vs. Resort Hotel



Para profundizar en el problema, se dividió la métrica de cancelación según el tipo de establecimiento. Los gráficos combinados (*Cancellation Count* y *Cancellation % in City Hotel and Resort Hotel*) revelan realidades comerciales completamente distintas:

- **Evidencia visual:**

1. City Hotel (Hotel de Ciudad): Presenta el mayor volumen total de operaciones, pero también la peor tasa de retención. El **42.2%** de sus reservas son canceladas.
2. Resort Hotel (Hotel Vacacional): Aunque maneja un volumen menor de clientes, es mucho más estable. Solo el **28.3%** de sus reservas son canceladas (casi 14 puntos porcentuales menos que el hotel de ciudad).


- **Insights:**


1. **Diferencia en el comportamiento del viajero:** La brecha entre ambos hoteles indica que el motivo del viaje influye radicalmente en el compromiso del cliente. Los clientes del *City Hotel* (probablemente viajeros de negocios o de escapadas cortas de fin de semana) tienen planes mucho más volátiles y cambian de opinión con facilidad.

-
2. **El efecto "Planificación":** Por el contrario, las reservas del *Resort Hotel* suelen ser vacaciones familiares planeadas con meses de antelación, que a menudo involucran la compra de vuelos y coordinación de fechas. Esta logística hace que al cliente le resulte mucho más difícil y costoso cancelar.
 3. **Foco de acción:** El riesgo financiero del grupo hotelero está claramente concentrado en el *City Hotel*. Cualquier estrategia de marketing, exigencia de depósitos previos o políticas restrictivas de cancelación debería probarse primero en el hotel de ciudad, que es donde existe la mayor fuga de capital.

3.3. Análisis por Tipo de Cliente: La dependencia de la volatilidad

**Transient Bookings Dominate the Customer Base
(Distribution of Customer Types)**








Para entender quiénes son los clientes que más cancelan, se analizó la composición de la base de usuarios (*Customer Type*) cruzándola con su comportamiento de cancelación.

- **Evidencia visual:** El gráfico de pastel muestra que el hotel tiene una dependencia absoluta del cliente individual o de paso (*Transient*), el cual representa el **75%** del total de las reservas. Las reservas de Grupos (*Group*) o por Contrato (*Contract*) son residuales.
 1. Al observar la tasa de cancelación (*Cancellation % by client type*), descubrimos que este grupo mayoritario (*Transient*) es, con diferencia, el más inestable, cancelando el **41.4%** de sus reservas. En el extremo opuesto, los clientes de Grupo solo cancelan un **7.8%**.
- **Insights:**
 1. **Riesgo de modelo de negocio:** El hotel sostiene sus ingresos sobre el segmento de clientes más volátil del mercado. Los viajeros individuales suelen reservar por internet, comparan opciones constantemente y no tienen penalizaciones altas al cambiar de opinión.
 2. **Oportunidad de estabilización:** La baja tasa de cancelación en Grupos (7.8%) sugiere que el equipo comercial (*B2B*) debería hacer un esfuerzo mayor para captar agencias, eventos corporativos o viajes organizados. Aumentar la cuota de estos clientes, aunque sea un 5% o un 10%, inyectaría una gran estabilidad financiera y previsibilidad al hotel, reduciendo la incertidumbre diaria.

3.4. El Valor de la Fidelización: Clientes Nuevos vs. Recurrentes

New Guest Dominates the Customer Base



Finalmente, se evaluó el impacto del historial del cliente en la probabilidad de que la reserva llegue a término.

- **Evidencia visual:**


1. El gráfico de pastel revela un problema severo de retención: el **97.2%** de las reservas provienen de clientes nuevos. Apenas un 2.8% de los huéspedes decide volver al hotel.
2. Sin embargo, al comparar su comportamiento, la diferencia es abismal. Los clientes nuevos cancelan el **38.2%** de las veces, mientras que los

clientes recurrentes (*Repeated Guest*) tienen una tasa de cancelación de apenas el **16.2%** (menos de la mitad).

- **Insights:**

1. **La lealtad como seguro anti-cancelación:** Queda demostrado estadísticamente que un cliente que ya conoce el hotel tiene un compromiso real con su viaje. La familiaridad con el servicio y las instalaciones reduce casi a cero las dudas de última hora que motivan las cancelaciones en los clientes nuevos.
2. **Foco urgente en la retención:** El hotel está operando como una "puerta giratoria" (atrae muchos clientes, pero no los retiene). Desde una perspectiva de negocio, es mucho más caro adquirir un cliente nuevo (marketing, comisiones a plataformas como Booking/Trip) que convencer a uno antiguo de que regrese.
3. **Plan de acción inmediato:** El hotel debe implementar un programa de fidelización (*Loyalty Program*). Ofrecer beneficios como descuentos directos, *late check-out* o *upgrades* de habitación a los clientes que repitan reserva no debe verse como un gasto, sino como una inversión para reducir ese 38.2% de cancelaciones que tanto daño hacen a la rentabilidad.

3.5. Anomalías en la Política de Depósitos: El caso "Non Refund"



El análisis de los tipos de garantía o depósito (*Deposit Type*) arrojó el descubrimiento más contraintuitivo y alarmante de todo el conjunto de datos.


- **Evidencia visual:** El gráfico muestra que la gran mayoría de las reservas se hacen sin depósito (*No Deposit*), manteniendo una tasa de cancelación del **28.8%**. Sin embargo, las reservas catalogadas como "No Reembolsables" (*Non Refund*) presentan una tasa de cancelación masiva del **99.4%**.

- **Insights:**

1. **Fallo en el sistema o fraude:** En la teoría hotelera, un depósito no reembolsable asegura la reserva. Que el 99.4% de estas se cancelen indica una grave anomalía operativa. Es altamente probable que estemos ante reservas falsas, fraudes con tarjetas de crédito inválidas, o agencias de viaje de terceros (*bots*) bloqueando habitaciones masivamente y cancelándolas antes de que se efectúe el cobro real.

2. **Acción requerida:** El departamento de IT y Operaciones debe auditar urgentemente la pasarela de pagos de este tipo de reservas para frenar este bloqueo irreal de habitaciones.


3.6. El Riesgo de la Antelación (Lead Time)



Se analizó cómo el tiempo que transcurre entre el día que se hace la reserva y el día de llegada al hotel afecta a la probabilidad de cancelación.

- **Evidencia visual:** El gráfico de líneas muestra una correlación positiva muy clara. Cuando las reservas se hacen con poca antelación (menos de 50 días), la tasa de cancelación es baja (alrededor del 20-30%). Sin embargo, a medida que la antelación aumenta, la línea sube drásticamente, superando el **60%** de probabilidad de cancelación para reservas hechas con más de 225 días de anticipación.
- **Insights:**
 1. **La volatilidad de los planes a largo plazo:** Una reserva hecha a más de 8 meses vista no es una venta segura, es simplemente una "intención" de viaje. Los planes de los clientes cambian, surgen imprevistos o encuentran mejores ofertas con el paso de los meses.
 2. **Estrategia de re-confirmación:** Para reservas a muy largo plazo, el hotel no debería cruzar los brazos y esperar. Se recomienda implementar un sistema de correos electrónicos automatizados (a los 3 meses y al mes antes de la llegada) para mantener el interés del cliente o pedirle una reconfirmación, limpiando así el sistema de reservas que el cliente ya olvidó que hizo.


3.7. El Precio (ADR) no es el culpable principal



Un supuesto común en la hotelería es que "cuanto más cara es la habitación, más se cancela". Se analizó el *ADR* para comprobar si esta hipótesis era cierta.

- **Evidencia visual:** El gráfico demuestra que el precio tiene un comportamiento errático. Para el grueso de las reservas (precios entre 50 y 300), la tasa de cancelación se mantiene oscilando en una franja horizontal estable de entre el 35% y el 45%. (Las caídas abruptas al final de la gráfica se deben estadísticamente a la falta de volumen de datos en precios extremadamente altos).
- **Insights:**
 1. **Aceptación del precio:** El precio no es el principal motor de las cancelaciones. Si un cliente reserva una habitación a un precio alto, es porque ya ha aceptado ese valor. Las razones de su cancelación posterior responden a cambios de planes (Lead Time) o falta de compromiso, no a la tarifa en sí.

3.8. La Psicología del Cliente: Peticiones Especiales




Finalmente, se midió el impacto de las peticiones especiales (*Special Requests*), como pedir una cuna, camas separadas o una habitación en piso alto.

- **Evidencia visual:** Los gráficos de barras muestran una correlación inversa y contundente. Un cliente que no hace ninguna petición (0) tiene una altísima tasa de cancelación (48.5%). Sin embargo, a medida que el cliente hace 1, 2, 3 o más peticiones, la tasa de cancelación se desploma drásticamente, llegando a un minúsculo 2.6% para aquellos que hacen 5 peticiones.

- **Insights:**

1. **El nivel de compromiso:** Este hallazgo es pura psicología del consumidor. Un cliente que se toma el tiempo de escribir al hotel para pedir que le preparen una cuna para su bebé, o que le den una habitación con vistas, es un cliente que ya está "visualizando" sus vacaciones. Su nivel de compromiso emocional con el viaje es altísimo.
2. **Acción comercial:** Durante el proceso de reserva en la web, el hotel debe *animar* activamente a los usuarios a personalizar su estancia. Cuantas más opciones elijan para adaptar la habitación a sus gustos, más difícil será que cancelen posteriormente.

3.9. Estacionalidad y Estrategia de Precios (ADR)



Se analizó la evolución de la Tarifa Diaria Promedio (*ADR*) a lo largo del año para ambos hoteles.

- **Evidencia visual:** El gráfico de líneas muestra dos curvas de precios muy distintas. El **City Hotel** tiene precios relativamente estables (entre 80 y 120 de ADR), con picos suaves en primavera (mayo) y finales de verano. Por el


contrario, el **Resort Hotel** tiene una curva agresiva: sus precios se desploman en invierno (50 de ADR en enero/noviembre) y explotan en agosto, superando los 180 de ADR.

- **Insights:**

1. **Modelos de negocio diferentes:** El Resort es altamente dependiente de la temporada de vacaciones de verano. Su estrategia debe centrarse en maximizar el beneficio en esos 3 meses (julio-septiembre) para compensar los meses de invierno, donde prácticamente opera a precio de coste.
2. **Flexibilidad del City Hotel:** El hotel de ciudad mantiene una demanda constante impulsada por el turismo de fin de semana y los negocios. Tiene margen para aplicar estrategias de precios dinámicos más sutiles y estables durante todo el año, sin depender de un único mes salvavidas.

3.10. Distribución y Dependencia de Terceros (OTAs)

From where are they booking?							
distribution_ channel ▲	Aviation	Complem entary	Corporate	Direct	Groups	Offline TA/TO	Online TA
Corporate	221	4	4539	82	1208	211	43
Direct		44	163	11892	1437	16	125
GDS				1		44	144
TA/TO	10	15	330	229	16908	23555	55702



Para entender cómo llegan los clientes al hotel, se analizaron los segmentos de mercado y los canales de distribución.

- **Evidencia visual:** Ambos gráficos muestran un dominio absoluto del canal "Online TA" (Agencias de Viaje Online) y "TA/TO" (Operadores Turísticos). El canal "Direct" (reservas directas en la web del hotel o por teléfono) representa una porción muy pequeña del pastel.
- **Insights:**
 1. **Dependencia y pérdida de margen:** El hotel depende casi por completo de plataformas de terceros para sobrevivir. Estas agencias (OTAs) cobran comisiones muy altas, lo que reduce severamente el margen de beneficio neto del hotel.
 2. **Estrategia de Venta Directa:** Es imperativo derivar presupuesto de marketing para potenciar el canal directo. Ofrecer el desayuno gratis o un 5% de descuento por reservar en la web oficial del hotel será, a largo plazo, mucho más rentable que seguir pagando comisiones masivas a las agencias.
- **Conclusión General del Análisis**

Tras la exploración exhaustiva de los datos, queda claro que las cancelaciones hoteleras son un fenómeno predecible. El "cliente de alto riesgo" tiene un perfil muy definido: es un huésped nuevo, que reserva de forma individual (*Transient*), con muchos meses de antelación y sin hacer

ninguna petición especial para su estancia. Al identificar estos factores, la gerencia del hotel cuenta ahora con evidencia empírica para dejar atrás las políticas genéricas y comenzar a aplicar estrategias quirúrgicas de precios, fidelización y marketing.

3.11. Modelado Predictivo (Machine Learning)

Para llevar el análisis descriptivo al siguiente nivel, se desarrolló un sistema predictivo utilizando algoritmos de Machine Learning en Python. El objetivo fue crear un modelo capaz de predecir de forma automática si un cliente cancelará su reserva.

a. Preparación de los Datos y Prevención de Riesgos


Antes de entrenar los modelos, se realizó una preparación avanzada de los datos. Se eliminaron columnas retrospectivas (como *reservation_status*, *reservation_status_date*) para evitar la "fuga de datos" (Data Leakage) y asegurar que el modelo prediga usando solo la información disponible en el momento de la reserva. Además, se transformaron las variables de texto en numéricas y se estandarizaron las escalas mediante *StandardScaler* (Pedregosa et al., 2011).

Asimismo, se llevó a cabo un tratamiento riguroso de valores atípicos (*outliers*) en variables críticas como la tarifa diaria promedio (ADR), estableciendo límites lógicos (entre 0 y 1000€) para evitar que registros erróneos o extremos sesgan la capacidad de generalización del algoritmo.


b. Evolución y Entrenamiento de Modelos

Se probaron diferentes algoritmos para encontrar el equilibrio perfecto entre exactitud y comprensión del negocio:

- **Regresión Logística:** Se utilizó como primer punto de referencia por su alta interpretabilidad. Este modelo estableció una base sólida con una exactitud general del **79.03%**. Demostró ser bastante fiable al emitir alertas de cancelación (Precisión del 76.69%); sin embargo, su capacidad para detectar a *todos* los clientes en riesgo fue moderada (Recall del 62.38%), lo que significa que eludía casi un 38% de las cancelaciones reales (F1-Score: 68.80%).
-




- **Árbol de Decisión:** Se desarrolló un modelo de poca profundidad (3 capas) puramente con fines analíticos. Su representación gráfica permitió explicar de forma visual y transparente el proceso de decisión del cliente.



- **Random Forest :** Fue la solución definitiva para lidiar con el comportamiento complejo de los usuarios. Se aplicó la técnica *GridSearchCV* para probar


miles de combinaciones de parámetros y encontrar la configuración óptima, evitando que el modelo "memorizara" los datos (overfitting).



c. Resultados y Feature Importance

El modelo optimizado de Random Forest alcanzó una **Accuracy del 86.7%** en datos de Set de Prueba. Además de su alta precisión, el modelo generó un ranking automático de las variables que más provocan las cancelaciones (Feature Importance), confirmando empíricamente los hallazgos del análisis visual previo. Los tres factores predictivos más fuertes son:

1. **Lead Time:** El factor de riesgo número uno.
 2. **Deposit Type:** Confirmando la anomalía técnica o de canal descubierta en el análisis exploratorio.
 3. **ADR:** La sensibilidad al precio ante ofertas de la competencia.
-



4. Definición del sistema BI

La arquitectura del sistema de Business Intelligence (BI) diseñada para este proyecto actúa como el puente entre los datos transaccionales brutos y la toma de decisiones ejecutivas. Para garantizar su escalabilidad y rendimiento, el sistema se ha estructurado en dos capas: la **Capa de Negocio** (orientada a KPIs y estrategia) y la **Capa de BackOffice** (orientada a la ingeniería y procesamiento de datos) siguiendo la metodología de modelado dimensional propuesta por Kimball y Ross (2013).

a. Capa de Negocio

Esta capa define la lógica empresarial. Asegura que el modelado técnico posterior responda directamente a los problemas financieros y operativos detectados en la cadena hotelera.

- **Objetivos Estratégicos:** El sistema se rige por tres directrices:
 - **Mitigar la pérdida de ingresos (*Lost Revenue*):** Reduciendo la actual tasa de cancelación global del 37,6%.
 - **Optimizar el *Yield Management* (Gestión de ingresos):** Maximizando el precio de venta en temporada alta, especialmente en el *Resort Hotel* durante los meses de verano.

-
- **Incrementar el *Life Time Value* (LTV) del cliente:** Desarrollando estrategias de retención para superar el actual déficit de fidelización (donde solo el 3% son huéspedes recurrentes).
 - **Información y KPIs:** Para monitorizar la salud del negocio, el sistema calcula las siguientes métricas en tiempo real:
 - **Cancellation Rate (%)**: Tasa de abandono, segmentable por tipo de hotel, antelación (*Lead Time*) y canal.
 - **ADR (Average Daily Rate)**: Tarifa media diaria, fundamental para evaluar la elasticidad y competitividad del precio.
 - **Total Revenue & Lost Revenue**: Cuantificación financiera de las operaciones (43M generados frente a 17M perdidos por cancelaciones).
 - **Distribución de Canales**: Cuota de mercado por agencia (*Online TA*, *Direct*, *Corporate*).
 - **Acciones Basadas en Datos:** A partir de los *insights* generados, el sistema propone directrices claras:
 - **Auditoría de pasarelas de pago**: Investigar las anomalías en los depósitos "Non-Refundable" (que presentan un 99,4% de cancelación).
 - **Implementación de un *Loyalty Program***: Campañas específicas para convertir clientes transitorios (*Transient*) en huéspedes recurrentes.
 - **Protocolos de re-confirmación**: Automatizar comunicaciones para reservas con un *Lead Time* superior a 250 días, donde el riesgo de cancelación supera el 60%.

b. Capa de BackOffice

Esta capa define la infraestructura de datos y el flujo técnico (*Pipeline*) necesario para alimentar el cuadro de mando final con información estructurada y libre de errores.

- **Identificación y Origen de los Datos:** El sistema se alimenta de un *dataset* transaccional histórico (extraído de Kaggle) que simula el volcado de un sistema PMS (*Property Management System*) hotelero. El volumen de datos inicial consta de más de 117.000 registros y más de 30 variables operativas.
 - **Proceso ETL :** Se ha diseñado un *pipeline* híbrido:
-

-
- **Pandas:** Empleado para la limpieza estructural pesada (*Data Cleaning*), eliminación de *outliers* lógicos (reservas con cero huéspedes o ADR negativo), y *Feature Engineering* (creación de nuevas variables derivadas como *total_nights* o *total_person*).
 - **Power Query:** Utilizado para la etapa final de normalización, asegurando la integridad referencial y asignando claves primarias y foráneas para la conexión de tablas.
 - **Almacenamiento y Modelado de Datos:** La arquitectura se basa en un Modelo en Estrella. Esta estructura centraliza los registros cuantitativos en una Tabla de Hechos (*Bookings*) rodeada de Tablas de Dimensiones descriptivas (*Dim_Hotel*, *Calendar*, *Dim_profil_Customer*, *Dim_Market_Channel*). Este diseño, alojado en el motor analítico en memoria VertiPaq de Power BI, garantiza una compresión óptima y permite manejar cientos de miles de filas sin latencia para el usuario final.
 - **Procesamiento y Cálculo (Motor DAX):** La inteligencia analítica del sistema recae sobre el lenguaje **DAX**. Mediante este lenguaje se han programado medidas explícitas que permiten cálculos de agregación compleja y funciones de Inteligencia de Tiempo (*Time Intelligence*). Esto permite que métricas como el *Lost Revenue* se recalculen en fracciones de segundo ante cualquier segmentación transversal aplicada por el gerente (ej. filtrar ingresos del *City Hotel* generados exclusivamente en fines de semana).

5. Solución BI / Cuadro de mando

Para materializar todo el esfuerzo técnico de limpieza y modelado de datos, se ha desarrollado una solución integral de Business Intelligence a través de un Cuadro de Mando (*Dashboard*) interactivo en Power BI. Esta herramienta transforma más de 117.000 registros históricos en una interfaz visual, intuitiva y orientada a la acción.

5.1. Construcción de la Solución

El cuadro de mando se construyó siguiendo las mejores prácticas de desarrollo en Power BI:

- **Base de Datos y Cálculos:** La herramienta se alimenta del Modelo en Estrella previamente definido. Se utilizó el lenguaje DAX para programar medidas complejas de negocio que no existían en los datos crudos,
-


destacando la creación de KPIs financieros críticos como el *Total Revenue* (Ingresos Totales: 43M) y el *Total Lost Revenue* (Ingresos Perdidos por cancelaciones: 17M).

- **Diseño UX/UI:** Se diseñó una interfaz limpia apoyada en una paleta de colores coherente (tonos lavanda y azul oscuro) para no saturar la vista. Se implementó una barra de navegación superior mediante botones con marcadores (*Bookmarks*) que permite saltar entre páginas de forma fluida, como si fuera una página web.
- **Panel de Filtros Global (Slicers):** En el margen derecho de todas las páginas, se integró un panel de control estático. Este incluye filtros por tipo de hotel (City/Resort), un control deslizante de fechas y menús desplegables de Año y Mes. Esto permite que cualquier gráfico del cuadro de mando responda dinámicamente al contexto temporal deseado.

5.2. Características y Funcionalidades por Página


La solución consta de tres pantallas principales, cada una diseñada para responder a preguntas de negocio específicas:

A. Página 1: Hotel Booking Demand Overview (Visión General)




- **Funcionalidad:** En la parte superior, presenta un resumen ejecutivo con los KPIs más importantes (Reservas, Cancelaciones, Tasa de No-Show al 1.01% e Impacto Financiero). Debajo, gráficos de líneas evalúan la estacionalidad de la demanda y del precio (ADR) a lo largo de los meses, comparando ambos hoteles.
- **Destacado:** Incluye una matriz detallada que cruza el Canal de Distribución con el Segmento de Mercado, permitiendo identificar rápidamente de dónde provienen las reservas más voluminosas (ej. TA/TO Online).

B. Página 2: Client Analysis (Perfil del Huésped)



- **Funcionalidad:** Profundiza en quién es el cliente. Revela que el hotel aloja a más de 231.000 personas. Mediante gráficos de barras y anillos, desglosa el país de origen (liderado por Portugal - PRT), el tamaño promedio del grupo (mayoritariamente 2 personas), la antelación de la compra (> 4 semanas) y la fidelidad del cliente.
- **Destacado:** El gráfico de "New vs Repeated Guest" expone visualmente el grave problema de retención del hotel (97% clientes nuevos).

C. Página 3: Cancellation Rate Analysis (Diagnóstico de Cancelaciones)



- **Funcionalidad:** Esta página abandona los recuentos absolutos y se centra en los porcentajes de riesgo. A través de gráficos de áreas y líneas, muestra cómo fluctúa la tasa de cancelación dependiendo de cuán cara sea la habitación (ADR) o de cuántos días falten para la llegada (*Lead Time*).
- **Destacado:** Muestra claramente el efecto protector de las "Peticiónes Especiales" y la alarmante anomalía de las reservas con depósito "Non Refund".

5.3. Toma de Decisiones Empresariales

Este cuadro de mando dejará de ser un simple reporte estático para convertirse en el motor de decisiones del hotel. Se utilizará para:

1. **Recuperación de Ingresos:** La visualización de los "17 Millones perdidos" por cancelaciones servirá para justificar un cambio inmediato en las políticas de reserva, endureciendo las condiciones para las estancias largas en el *City Hotel*.
2. **Campañas de Marketing Dirigidas:** Al observar que la mayoría de los clientes provienen de Portugal (PRT), Reino Unido (GBR) y Francia (FRA), el equipo de marketing dejará de gastar presupuesto en publicidad global y lanzará campañas de fidelización hiper-segmentadas en esos tres países para revertir el 97% de clientes nuevos.

-
3. **Fijación Dinámica de Precios:** El equipo comercial utilizará el gráfico de estacionalidad (Overview) para anticiparse. Sabiendo exactamente en qué semanas caen las reservas y suben los precios, podrán lanzar ofertas preventivas en los meses valle (invierno) y maximizar el ADR en los picos de verano sin miedo a vaciar el hotel.
 4. **Gestión de Recepción:** Sabiendo que los grupos son mayoritariamente de 2 personas y que las peticiones especiales reducen las cancelaciones (Página 3), recepción enviará correos automáticos ofreciendo *upgrades* románticos o servicios extra a las parejas semanas antes de su llegada para "atar" emocionalmente esa reserva.

6. Gestión de proyecto

La ejecución del proyecto se estructuró bajo una metodología **ágil** adaptada (**Scrum**), dividiendo el marco temporal de 30 días en entregables iterativos. Esto permitió adaptar el desarrollo a la curva de aprendizaje técnico y garantizar el cumplimiento de los plazos.

6.1. Cronograma y Sprints (1 Mes)

El trabajo intensivo de 4 semanas se dividió en cuatro *sprints* funcionales:

- **Sprint 1 (Semana 1) - ETL:** Comprensión del negocio, descarga de datos (Kaggle) y programación del *pipeline* de limpieza y transformación en Python (Pandas).
- **Sprint 2 (Semana 2) - Modelado:** Capacitación técnica intensiva y construcción de la arquitectura de datos relacional (*Star Schema*) en Power BI.
- **Sprint 3 (Semana 3) - Lógica DAX y UI/UX:** Traducción de las reglas de negocio a fórmulas DAX para calcular los KPIs financieros y operativos (+6 métricas críticas). Diseño de la interfaz interactiva, optimización del rendimiento visual
- **Sprint 4 (Semana 4) - Machine learning y Cierre:** Entrenamiento de modelos y redacción del reporte.

6.2. El Triángulo de Gestión (Alcance, Tiempo y Coste)

El proyecto se rigió por las siguientes restricciones operativas:

- **Alcance (Scope):**
 - *In-Scope*: Entregar un modelo de datos robusto y un *Dashboard* navegable con al menos 6 métricas críticas y desarrollar modelos predictivos (*Machine Learning*) .
 - *Out-of-Scope*: Se excluyó la conexión de datos en tiempo real, priorizando la exactitud del análisis descriptivo.
- **Tiempo (Time)**: Ejecución total en **50 horas efectivas**, distribuidas estratégicamente:
 - **5h**: Búsqueda, evaluación y descarga de datos.
 - **10h**: Procesamiento, limpieza e integración (ETL en Pandas).
 - **15h**: Capacitación técnica y desarrollo de visualizaciones (Power BI).
 - **10h**: Desarrollo de modelos predictivos (*Machine Learning*).
 - **10h**: Documentación técnica, validación y reporte final.
- **Coste (Cost)**: *Gasto Real (Académico)*: **0 €** en infraestructura. Se empleó software gratuito (Google Colab, librerías de Python y Power BI Desktop).

6.3. Gestión de Riesgos y Conocimiento

- **Riesgo Principal**: La pronunciada curva de aprendizaje técnico requerida para dominar Power BI y DAX desde cero.
 - **Plan de Mitigación**: Se implementó una estrategia de capacitación "**Just-in-Time**". En lugar de detener el proyecto, se asignaron horas específicas del cronograma a la investigación y el autoaprendizaje (mediante tutoriales y documentación técnica). Esto transformó una barrera técnica en una ventaja de desarrollo ágil, logrando cumplir el alcance sin desvíos temporales.
-

7. Conclusiones y recomendaciones

Tras la ejecución integral de este proyecto, desde la limpieza de datos en Python hasta la visualización analítica en Power BI, se ha logrado transformar la incertidumbre operativa del hotel en información medible y accionable.

7.1. Conclusiones Principales del Negocio

El análisis de los más de 117.000 registros históricos ha revelado los siguientes hallazgos críticos:

- **Fuga masiva de ingresos:** La tasa global de cancelación se sitúa en un 37,6%, lo que se traduce en un impacto financiero negativo de 17 millones (*Lost Revenue*). Este problema es significativamente más grave en el *City Hotel* (42,2%) que en el *Resort Hotel* (28,3%).
- **El escudo de la fidelización:** El hotel sufre una dependencia absoluta de la captación constante (97% de los huéspedes son nuevos). Sin embargo, los datos demuestran que los clientes recurrentes cancelan a un ritmo muchísimo menor (16,2%) frente a los nuevos (38,2%).
- **Anomalías en el sistema:** Se ha detectado una tasa de cancelación irreal (99,4%) en las reservas vinculadas a depósitos "No Reembolsables", lo que indica un probable fallo en la pasarela de pagos, reservas fraudulentas o bloqueos masivos por parte de *bots*.
- **Factores predictivos:** Las reservas hechas con mucha antelación (*Lead Time* alto) y sin requerimientos especiales tienen la mayor probabilidad de ser canceladas. Por el contrario, la personalización de la estancia (peticiones especiales) asegura casi al 100% la llegada del cliente.

7.2. Recomendaciones Estratégicas

Basado en la evidencia de los datos, se aconseja a la gerencia:

1. **Auditar los pagos:** Investigar de urgencia el origen de las reservas con depósito no reembolsable para detener el bloqueo irreal de habitaciones.
 2. **Invertir en el cliente recurrente:** Crear un programa de lealtad (*Loyalty Program*) e incentivar la reserva directa (*Direct Channel*) para reducir la alta dependencia de las agencias de viaje online (OTAs) y evitar sus altas comisiones.
-

-
3. **Gestión proactiva:** Implementar correos de re-confirmación para reservas hechas con más de 3 meses de antelación y ofrecer activamente servicios extra para aumentar el compromiso emocional del huésped.

7.3. Recomendaciones para la Escalabilidad del Proyecto

Actualmente, el cuadro de mando funciona con un archivo histórico estático (CSV descargado de Kaggle). Para que este proyecto escale de un entorno académico a un **sistema empresarial de grado de producción**, se recomiendan los siguientes pasos:

- **Migración a la Nube (Cloud Architecture):** Automatizar la extracción de datos conectando el sistema del hotel (PMS) directamente a un almacén de datos en la nube (como Azure SQL Database o Google BigQuery).
 - **Actualización Automatizada:** Configurar actualizaciones programadas (*Scheduled Refresh*) o conectividad *DirectQuery* en el servicio web de Power BI, permitiendo que la gerencia vea los datos de reservas y cancelaciones en tiempo real sin intervención manual de un analista.
 - **Integración de Machine Learning:** Como prueba de concepto de la escalabilidad del sistema, se ha desarrollado con éxito un modelo predictivo basado en Random Forest. Este modelo, tras ser optimizado mediante *GridSearchCV*, alcanzó una exactitud del **86.7%**. Su integración permite asignar una "Probabilidad de Cancelación" a cada reserva en tiempo real, transformando el sistema de un análisis descriptivo a una herramienta de prescripción científica para la gestión de *overbooking*.
-

8. Referencia

Antonio, N., de Almeida, A., & Nunes, L. (2019). Hotel booking demand datasets. Data in Brief, 22, 41-49. <https://doi.org/10.1016/j.dib.2018.11.126>

Breiman, L. (2001). *Random Forests*. Machine Learning, 45(1), 5-32.

Mostipak, J. (2020). Hotel booking demand. Kaggle. <https://www.kaggle.com/datasets/jessemostipak/hotel-booking-demand/data>

Google. (2024). Gemini (Modelo de Lenguaje Extenso) [Software]. <https://gemini.google.com/>

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. Computing in Science & Engineering, 9(3), 90-95. <https://doi.org/10.1109/MCSE.2007.55>

Kimball, R., & Ross, M. (2013). The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling (3rd ed.). John Wiley & Sons.

Pedregosa, F., et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825-2830. (Esta es la referencia oficial de la librería que usamos para todos los modelos, el escalado y el GridSearchCV).

McKinney, W. (2010). Data Structures for Statistical Computing in Python. En Proceedings of the 9th Python in Science Conference (pp. 51-56).

Microsoft. (2024). Referencia de expresiones de análisis de datos (DAX). Microsoft Learn. Recuperado de <https://learn.microsoft.com/es-es/dax/>

Waskom, M. L. (2021). seaborn: statistical data visualization. Journal of Open Source Software, 6(60), 3021. <https://doi.org/10.21105/joss.03021>

VanderPlas, J. (2016). *Python Data Science Handbook: Essential Tools for Working with Data*. O'Reilly Media, Inc. (Una referencia excelente para el flujo de trabajo de ciencia de datos que seguimos).

9. Anexo de Registro de Prompts Reales Utilizados en el Proyecto

La integración de herramientas de Inteligencia Artificial (IA) ha sido fundamental para la optimización de este proyecto (Google, 2024). Siguiendo las normativas de transparencia, a continuación se detallan los usos específicos realizados durante cada fase:

Fase 1: Programación, ETL y Configuración Técnica

Consulta: "[Código de gráfico] ¿Por qué con este código no me sale el label de key point?"

Resultado: Solución técnica mediante la inclusión de `plt.legend()`.

Consulta: "¿Cómo puedo transformar columnas de texto como 'is_canceled' o 'is_repeated_guest' a un formato no numérico creando nuevas columnas para Power BI?"

Resultado: Código de transformación de variables para facilitar el modelado posterior y permitir cálculos matemáticos (como la tasa de cancelación).

Consulta: "Necesito ver la estacionalidad, ¿cómo extraigo el mes o el año de la columna de fecha de reserva usando Pandas para crear una nueva columna temporal?"

Resultado: Instrucciones sobre el uso de la librería de fechas de Pandas (`dt.month`) para generar dimensiones de tiempo útiles para el Business Intelligence.

Consulta: "¿Cómo puedo hacer que el eje Y empiece por 0? [Código adjunto]"

Resultado: Implementación de `ax.set_ylim(bottom=0)` para evitar sesgos visuales.

Consulta: "¿Cómo se llama este palette en pandas matplotlib? [Imagen adjunta de gráfico de barras]"

Resultado: Identificación de la paleta "husl" de Seaborn.

Consulta: "¿Me puedes recomendar otro palette que tenga estos colores o parecidos ['#5A9CB5', '#FACE68']?"

Resultado: Sugerencia de paletas 'Set2', 'colorblind' y creación de una paleta personalizada.

Consulta: "¿Cómo guardo este dataframe final, ya sin nulos y con las nuevas columnas, en un archivo CSV limpio sin que se exporte la columna del índice?"

Resultado: Código de exportación final (`to_csv(index=False)`) garantizando un formato de tabla plana ideal para importar directamente al Power Query de Power BI.

Fase 2: Modelado y Estrategia Power BI

Consulta: "Tengo dificultad para crear clave primaria con referenciar la tabla principal, ¿hay otra forma para hacerlo? por ejemplo, crear la columna de hotel_id (0, 1) primero en la tabla principal y luego separarlas dos columnas (hotel y hotel_id)?"

Resultado: Alternativa paso a paso para extraer la dimensión Dim_Hotel creando la columna condicional primero, sin usar la función "Merge".

Consulta: "Enséñame cómo crear customer_ID: Dim_Customer Para analizar orígenes, nuevos vs. recurrentes, y tipos. Columnas: Customer_ID (PK), country, customer_type, is_repeated_guest."

Resultado: Guía para crear una Clave_Cliente_Temporal (concatenación) y generar la dimensión basada en los atributos del cliente.

Consulta: "No he entendido por qué es necesario esta parte: Clave_Cliente_Temporal, creo que tiene un mismo country customer type and repeated guest, no significa que es la misma persona."

Resultado: Explicación conceptual sobre la diferencia entre rastrear "individuos únicos" vs. crear una dimensión de "perfiles demográficos" por falta de datos personales.

Consulta: "Me puedes explicar con más detalle sobre esta parte? La técnica del Merge: (Es la más segura aquí). En tu tabla principal, usas 'Combinar consultas' con Dim_Customer usando la Clave_Cliente_Temporal."

Resultado: Paso a paso detallado de cómo realizar un "Merge" en Power Query para conectar las tablas y limpiar la tabla principal.

Consulta: "¿Is merge queries o merge queries as new?"

Resultado: Aclaración de optimización sobre por qué usar "Combinar consultas" en lugar de crear una tabla nueva para no sobrecargar la memoria.

Consulta: "EN ESTE PASO Recuadro de abajo: Habrá un menú desplegable. Ábrelo y selecciona tu tabla Dim_Customer., me sale 'no preview is available' y no puedo seleccionar ninguna columna."

Resultado: Diagnóstico y pasos para "despertar" la consulta y forzar la actualización de la vista previa en Power Query.

Consulta: "He hecho todos los pasos que me has comentado, y me sigue saliendo no preview is available and value was not specified."

Resultado: Identificación del error de sintaxis ("value not specified") y sugerencia del "Plan C": usar una dimensión degenerada temporalmente.

Consulta: "Ya he encontrado el motivo: It happens especially if you 'referenced' a query to your main query... If referencing is the problem, just 'duplicate' your main query..."

Resultado: Confirmación del diagnóstico sobre el error de "Dependencia Circular" en el árbol de evaluación y validación de la solución aislando la consulta.

Consulta: "Necesito guía para hacer este: Dim_Market_Channel Para ver cómo están llegando esas reservas. Columnas: Market_Channel_ID (PK), market_segment, distribution_channel."

Resultado: Instrucciones para crear la dimensión de canales cruzando dos columnas a la vez, aplicando la técnica exitosa de "Duplicar".

Fase 3: Análisis Analítico e Interpretación de Resultados

Consulta: "Necesito tu ayuda para sacar una conclusión principal para este chart (boxplot), lo necesito para poner como título."

Resultado: Análisis de rentabilidad comparativa entre City y Resort Hotel.

Consulta: "Sácame conclusiones basándote en este gráfico de reservas confirmadas por mes"

Resultado: Análisis de estacionalidad bimodal y detección del "invierno slump".

Consulta: "Sácame una frase o dos de conclusión en inglés sobre el gráfico de Impacto del Lead Time."

Resultado: Correlación entre antelación de reserva y probabilidad de cancelación.

Consulta: "¿Qué significa TA/TO en la diferenciación de clientes (Transient, grupos, agencias)?"

Resultado: Definición técnica de Travel Agent y Tour Operator.

Fase 4: Modelado Predictivo (Machine Learning) y Optimización

Consulta: "Me puedes explicar con más detalle sobre estos dos códigos de StandardScaler: fit_transform en X_train y transform en X_test, ¿para qué es cada uno?"

Resultado: Explicación conceptual de la diferencia metodológica para evitar la "fuga de datos" (Data Leakage), garantizando que el modelo no aprenda de la distribución del conjunto de prueba.

Consulta: "Los top 3 features generados por el modelo son lead_time, deposit_type_Non Refund y adr, ¿cómo los interpreto?"

Resultado: Interpretación comercial y estratégica de las tres variables más importantes para la toma de decisiones del hotel, sirviendo como base para las conclusiones del reporte.

Consulta: "¿También debo probar Decision Tree?"

Resultado: Implementación de un Árbol de Decisión de profundidad limitada (`max_depth=3`) con el objetivo de generar un gráfico visual interpretable ("caja blanca") para explicar la lógica de cancelación a perfiles de negocio, complementando al modelo Random Forest.

Consulta: "¿Me puedes explicar la diferencia entre parámetros como '`min_samples_split`': [2, 10] y '`max_depth`': [15, 25, None] en GridSearchCV?"

Resultado: Explicación técnica sobre cómo la afinación de hiperparámetros (Hyperparameter Tuning) "poda" el árbol de decisión para evitar el sobreajuste (overfitting) y optimizar el rendimiento del ensamble.

Consulta: "¿Crees que hace falta hacer también KNN?"

Resultado: Justificación técnica arquitectónica para excluir el algoritmo K-Nearest Neighbors (KNN), debido a la "maldición de la dimensionalidad" generada por el escalado de variables categóricas y su ineficiencia en el tiempo de procesamiento.

Consulta: "¿Me puedes mirar si este código de *GridSearchCV* está bien? (Daba error de validación cruzada)"

Resultado: Auditoría de código que identificó un error de sintaxis en la métrica de evaluación (`scoring= 'accuracy'`) y optimización del script utilizando la librería estándar `accuracy_score`.

Consulta: "¿Cuál es la diferencia entre usar `df[...]` y `df.loc[...]` en Pandas?"

Resultado: Aclaración de buenas prácticas de programación en Pandas para manipulación de datos, destacando el uso de `.loc` para evitar el error crítico `SettingWithCopyWarning` al modificar el dataset.

Fase 5: Redacción, Estructura y Formato del Reporte

Consulta: "Revisar la primera parte de introducción y hacerlo más corto (Contexto, Motivación, Objetivos, Alcance)."

Resultado: Versión ejecutiva y sintetizada de la sección 1.

Consulta: "Revisar la sección 4 (Definición del sistema BI) y hacerlo más específico"

Resultado: Mejora de terminología técnica (Capa de Negocio vs BackOffice, ETL, DAX).

Consulta: "Revisar sección 6 (Gestión de proyecto) si hay errores."

Resultado: Estructuración del cronograma en Sprints y Triángulo de Gestión.

Consulta: "¿Qué fuente o forma puedo usar en Google Docs para diferenciar palabras de código como 'agent', 'company' o 'drop'?"

Resultado: Recomendación de uso de fuentes monoespaciadas (Consolas/Roboto Mono).
